



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE ESTUDIOS PROFESIONALES CAMPUS ACATLÁN

MODELOS EXPLICABLES DE MACHINE
LEARNING PARA LA PREDICCIÓN DEL CHURN Y
CALCULO DEL CHURN RATE

T E S I S

QUE PARA OPTAR POR EL GRADO DE:
Licenciado en Matemáticas Aplicadas y Computación

PRESENTA:

Carlos Espadin Medina

TUTOR:

Mtra. Jeanett López García



Ciudad de México, 2024

*A la Facultad de Ingeniería y a la Universidad, por la formación que me han dado.
Es gracias a ustedes que es posible el presente trabajo.
En verdad, gracias.
Yo.*

Reconocimientos

También quisiera reconocer a ... por ...CONACYT, PAPIIT / etc. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Declaración de autenticidad

Por la presente declaro que, salvo cuando se haga referencia específica al trabajo de otras personas, el contenido de esta tesis es original y no se ha presentado total o parcialmente para su consideración para cualquier otro título o grado en esta o cualquier otra Universidad. Esta tesis es resultado de mi propio trabajo y no incluye nada que sea el resultado de algún trabajo realizado en colaboración, salvo que se indique específicamente en el texto.

Carlos Espadin Medina. Ciudad de México, 2024

Resumen

This is where you write your abstract ...

Índice general

Índice de figuras	XI
Índice de tablas	XIII
1. Introducción	1
1.1. Presentación	1
1.2. Objetivo	1
1.3. Motivación	1
1.4. Planteamiento del problema	2
1.5. Preguntas de investigación	2
1.6. Hipótesis o supuestos del estudio	2
1.7. Metodología	2
1.8. Contribuciones	2
1.9. Estructura de la tesis	3
2. Marco teórico y conceptual	5
2.1. Fundamentos del aprendizaje automático (ML)	5
2.2. Aprendizaje Supervisado	8
2.2.1. Algoritmos de clasificación	10
2.2.1.1. Regresión logística	12
2.2.1.2. KNN	12
2.2.1.3. Random Forest	12
2.2.1.4. SVM	12
2.3. Predicción del churn.	12
2.3.1. Definición de <i>churn</i>	12
2.3.2. Cálculo del <i>churn</i>	12
2.3.3. Métricas y causalidad del <i>churn</i>	15
2.3.4. Análisis de Cohortes y la tasa de abandono	16
2.4. Inteligencia artificial explicable (XAI)	20
2.4.1. SHAP	20
2.4.2. LIME	20
2.4.3. Importancia de características	20

3. Metodología de análisis y preparación de los datos	23
3.1. Descripción del conjunto de datos	23
3.2. Preprocesamiento	24
3.2.1. Limpieza y tratamiento de valores faltantes y outliers	24
3.2.2. Transformaciones y codificación	24
3.2.3. Selección y reducción de características (PCA)	24
3.3. Construcción de la variable de abandono (churn)	24
3.4. Implementación de modelos de ML para predecir el abandono	25
3.4.1. Evaluación del modelo.	25
3.4.2. Comparación del rendimiento entre modelos.	29
3.4.3. IA Explicable.	36
4. Implementación y evaluación de modelos predictivos	39
4.1. Implementación de modelos de clasificación	39
4.1.1. Descripción de cada modelo y sus supuestos	39
4.2. Evaluación de desempeño de los modelos	39
4.2.1. Métricas: Accuracy, Precision, Recall, F1, AUC, PR	39
4.2.2. Comparación de resultados	39
4.3. Aplicación de XAI a modelos seleccionados	39
4.3.1. Interpretación de resultados y visualizaciones	39
5. Discusión y análisis de resultados	41
5.1. Discusión de hallazgos relevantes	41
5.2. Limitaciones del modelo	41
5.3. Recomendaciones para su implementación en entornos empresariales reales	41
6. Conclusiones y líneas futuras	43
6.1. Conclusiones generales	43
6.2. Aportaciones teóricas, metodológicas y prácticas	43
6.3. Sugerencias para investigaciones futuras	43
A. Código/Manuales/Publicaciones	45
A.1. Apéndice	45
Bibliografía	47

Índice de figuras

2.1. El enfoque tradicional	6
2.2. Enfoque de Machine Learning	7
2.3. Relación entre IA, ML, Deep Learning y tipos de aprendizaje automático	10
2.4. Tipos de aprendizaje automático con ejemplos de tareas y algoritmos . .	11
2.5. Histograma de Tiempo desde la ultima compra	14
2.6. Gráfica de tarda para el abandono de clientes.	15
2.7. Matriz de Cohortes.	21
3.1. Matriz de confusión para el modelo de multi-layer perceptron classifier.	25
3.2. Curva ROC.	28
3.3. Curva PR.	29
3.4. Matriz de confusión para el modelo de regresión logística del conjunto de entrenamiento y validación	30
3.5. Curva PR de Regresión Logística	30
3.6. Metricas de evaluación del modelo de regresión logística para el conjunto de entrenamiento y validación	31
3.7. Matriz de confusión para el modelo KNN del conjunto de entrenamiento y validación	31
3.8. Metricas de evaluación del modelo de KNN para el conjunto de entrena- miento y validación	32
3.9. Matriz de confusión para el modelo de soport vector machine del con- junto de entrenamiento y validación	33
3.10. Metricas de evaluación del modelo de SVM para el conjunto de entrena- miento y validación	33
3.11. Matriz de confusión para el modelo random forest del conjunto de en- trenamiento y validación	34
3.12. Metricas de evaluación del modelo de random forest para el conjunto de entrenamiento y validación	35
3.13. Curvas Roc de los modelos de clasificación para el conjunto de entrena- miento y validación respectivamente.	35
3.14. Gráfica de resumen global	36
3.15. Gráfica de explicación local	36
3.16. Gráfica de decisiones	37

Índice de tablas

Introducción

1.1. Presentación

1.2. Objetivo

El principal objetivo de este trabajo es desarrollar, analizar y modelar el comportamiento de los clientes de cualquier empresa en México, el enfoque de este trabajo puede ser dirigido tanto a empresas que ofrezcan servicios de retail, suscripciones, telecomunicaciones, financieros/bancarios o inclusive empresas de nicho como las pertenecientes al sector agrícola, todo esto utilizando técnicas de aprendizaje automático, más en específico usaremos modelos de clasificación para predecir su comportamiento, la idea es identificar patrones de conducta asociados a la retención y al abandono de clientes (Churn), haciendo uso de herramientas de ciencia de datos implementadas en Python. La finalidad es permitir a cualquier tipo de empresas anticipar las posibles pérdidas de clientes y diseñar diversas estrategias de fidelización.

1.3. Motivación

Popularmente se cree que adquirir nuevos clientes cuesta más que mantener los actuales, tal afirmación plantea la importancia que toma el análisis de churn en la toma de decisiones. Hoy en día, la retención de clientes representa uno de los mayores desafíos para las empresas en todo tipo de sectores, este caso de estudio se ha aplicado a empresas de retail, telecomunicaciones, servicios financieros, entre otros. La innovación científica y tecnológica en las empresas de México y todo el mundo avanza a pasos agigantados y con ella surgen distintas necesidades, el poder incorporar herramientas de análisis de datos para poder comprender mejor el comportamiento de sus clientes es una de ellas, en especial a la hora de comprender las razones por las cuales sus clientes dejan de consumir sus servicios/productos, por lo cual el análisis de abandono

1. INTRODUCCIÓN

de clientes se ha convertido en un requisito estratégico. Esta investigación surge por la motivación de integrar un enfoque cuantitativo, dirigido al Machine Learning, esto con un enfoque científico para poder ofrecer una solución innovadora a todo tipo sectores, incluso aquellos donde la digitalización aun esta en desarrollo.

1.4. Planteamiento del problema

El objetivo será desarrollar un modelo de explicativo y predictivo del Churn utilizando diferentes algoritmos de Machine Learning, comparando tanto modelos clásicos (por ejemplo regresión logística, maquinas de soporte vectorial, entre otros) así como modelos más complejos (XGBoost, redes neuronales, etc.), de tal manera que podamos estimar la capacidad de estos modelos para predecir el Churn y explicar el porqué ciertos clientes tienen más probabilidad de abandonar. La importancia de ofrecer una buena alternativa que explique y prediga dicho fenómeno ayudaría a poder generar hallazgos y accionables.

1.5. Preguntas de investigación

1.6. Hipótesis o supuestos del estudio

1.7. Metodología

La metodología propuesta para el desarrollo de este trabajo esta constituida por cuatro etapas primordiales, **primero** recopilación y preprocesamiento de los datos, **segundo** implementación de modelos de aprendizaje automático (Machine Learning y Deep Learning), **tercero** aplicación de técnicas de inteligencia artificial explicable (XAI) y finalmente en **cuarto** lugar la evaluación comparativa de los modelos. Dicha estructura nos va a permitir ofrecer un análisis predictivo y explicativo del Churn, de tal suerte que la comprensión e interpretación de los factores que explican el abandono de clientes se puedan aplicar de manera transversal a diferentes sectores de la iniciativa privada.

1.8. Contribuciones

Este trabajo plantea una serie de aportaciones tanto teóricas como prácticas en el campo de la ciencia de datos enfocados al Churn. Las principales aportaciones se describen a continuación:

1. Diseño de un pipeline generalizado y modular para la predicción del churn mediante aprendizaje automático.
2. Comparación sistemática entre modelos clásicos y avanzados de Machine Learning, integrando criterios de precisión y explicabilidad.
3. Aplicación práctica orientada a la toma de decisiones empresariales.
4. Contribución al debate sobre la explicabilidad en sistemas de inteligencia artificial aplicados a negocios.

1.9. Estructura de la tesis

Este trabajo está dividido en 5 capítulos, todos y cada uno de ellos responde a una fase del proceso de esta investigación, las cuales van desde la contextualización del problema (Churn) hasta el análisis de los resultados y las conclusiones. A continuación, describiremos brevemente el contenido de cada capítulo:

1. Introducción
2. Revisión de la literatura
3. Metodología
4. Resultados
5. Conclusiones

Marco teórico y conceptual

2.1. Fundamentos del aprendizaje automático (ML)

En los últimos años, la IA se ha vuelto parte de la cultura popular de nuestra sociedad y temas como el aprendizaje automático, ha alcanzado un hito en popularidad bastante marcado, esto debido a dentro de la misma inteligencia artificial esta es una de las ramas más destacadas, permitiendo a un sistema aprender de manera automática patrones a partir de datos y con los mismos poder realizar predicciones precisas a partir de los datos dados. En pocas palabras, el Machine Learning como nos referiremos al aprendizaje automático de ahora en adelante, busca que los sistemas informáticos “aprendan” de las experiencias de los datos, esto sin ser programados explícitamente para llevar a cabo una tarea en específico.

Sin embargo, pese a la reciente popularidad de la inteligencia artificial, que de ahora en adelante nos referiremos a ella como IA, y el creciente interés del público en general por todos los temas concernientes a la misma, es un hecho que desde mediados del siglo pasado se comenzó a gestar el desarrollo de la IA, y desde inicios de los 2000 diversas y discretas aplicaciones de la IA acompañaron la vida de las personas, desde integraciones en video juegos hasta motores de búsqueda como Google.

Una de las definiciones que mejor describe el machine learning es la citada por [Mitchell \(1997\)](#):

A computer program is said to learn from experience E with respect to some task T and some performance measure P , if its performance on T , as measured by P , improves with experience E .

—*Tom Mitchell, 1997*

A manera de ejemplo para poder entender como funciona el Machine Learning ([Géron, 2017](#), p. 4) explica esta definición usando como ejemplo el filtro de correos

2. MARCO TEÓRICO Y CONCEPTUAL

electrónicos de spam, la cual es una aplicación del machine learning, dice que el sistema puede aprender a marcar spam a partir de ejemplos de correos electrónicos spam (por ejemplo, marcados por los usuarios) y ejemplos de correos electrónicos normales (no spam, también llamados "ham"). Los ejemplos que el sistema utiliza para aprender se denominan conjunto de entrenamiento. Cada ejemplo de entrenamiento se denomina instancia de entrenamiento (o muestra). En este caso, la tarea T consiste en marcar el spam para los correos electrónicos nuevos, la experiencia E son los datos de entrenamiento y es necesario definir la medida de rendimiento P ; por ejemplo, se puede utilizar la proporción de correos electrónicos correctamente clasificados.

Esta explicación se puede extender de igual forma al problema central de esta tesis, el churn, pensemos que tradicionalmente una empresa tiene ciertas reglas de negocio para considerar a un cliente como perdido o Churn, más tarde ahondaremos en las posibles definiciones de dichas reglas, por el momento supongamos que una empresa define n cantidad de reglas para clasificar a sus clientes como churn y no churn, si dichas reglas se trasladan a un software el resultado sería algo muy similar al diagrama 2.1.




Figura 2.1: El enfoque tradicional

El problema de este enfoque tradicional es claro, una vez que se identifiquen las áreas de oportunidad en las reglas de negocio se tendrían que hacer adecuaciones en las mismas, quitar o añadir nuevas, principalmente esto ultimo paso va consumir mucho tiempo en mantenimiento y aumenta enormemente la complejidad de dichas validaciones, ya que por cada error cometido por el sistema se tendrían que estar añadiendo más y más reglas de negocio para obtener clasificaciones lo más certeras.

En cambio, si esta misma tarea la realizamos usando un enfoque de Machine Learning la trazabilidad cambia totalmente, ya que el algoritmo de ML (Machine Learning) aprende de manera automática las caracterizaras que son buenos predicadores de clientes churn y no churn, al igual que el sistema esta mucho más acotado, es más fácil de

entender y, muy probablemente, sea más preciso. El como abordar el Machine Learning este problema lo podemos ver más claramente en el diagrama 2.2, donde notamos que en esta ocasión en flujo del proceso ya no depende de reglas de negocio establecidas manualmente, esta vez son los datos históricos quienes alimentan al modelo. Este aprende por sí solo las relaciones complejas entre las variables que describen a los clientes, permitiendo generalizar a nuevos casos con mayor precisión.




Figura 2.2: Enfoque de Machine Learning

En este enfoque, los datos se convierten en el suministro más valioso, una vez que nuestro modelos este entrenado, se puede evaluar su rendimiento utilizando métricas objetivas del rendimiento, como la exactitud, la precisión, etc. Si el rendimiento no es el esperado, se pueden analizar los fallos, ajustar el modelo o incluso recolectar nuevos datos, para así reiniciar el bucle de aprendizaje.

Algunas de las ventajas del enfoque de Machine Learning son la *escalabilidad*, ya que los modelos pueden adaptarse sencillamente a nuevos datos sin tener que rescribir reglas de negocio de forma manual. Otra ventaja es **capacidad para detectar patrones complejos**, esto ya que los algoritmos de pueden reconocer correlaciones no lineales y dependencias que a simple vista sería muy difíciles de identificar mediante validaciones fijas. Por ultimo y no menos importante, **la capacidad de mejorar continuamente** el ciclo iterativo nos permite evolucionar progresivamente nuestro sistema esto conforme van cambiando ciertos patrones de comportamiento de los clientes. De tal suerte que aplicar modelos de Machine Learning en la predicción del churn no solo representa una mejora tecnológicamente hablando, sino también un cambio de paradigma en la manera en que las empresas pueden combatir el abandono de clientes.

2.2. Aprendizaje Supervisado

Ya hemos abordado una pequeña introducción al aprendizaje automático o machine learning, y como usando esta perspectiva podemos ayudarnos para resolver distintos problemas de la vida cotidiana en múltiples ámbitos, entre ellos el empresarial, además su implementación puede ser más práctica, escalable y fácil de mantener a lo largo del tiempo. Sin embargo, es necesario saber que el machine learning es un tipo de inteligencia artificial, y aun que anteriormente hemos mencionado con cierta naturalidad el concepto de inteligencia artificial es necesario dar un par de definiciones para entender mejor este concepto, según [Russell and Norvig, 2020](#):

”La inteligencia artificial es el estudio de los agentes que reciben percepciones del entorno y realizan acciones.”

[Russell and Norvig \(2020, p. 1\)](#)

Otra definición bastante interesante es la dada por [Luger, 2005](#):

”La inteligencia artificial es el estudio de los mecanismos computacionales para la percepción y el razonamiento, que pueden imitar la inteligencia humana.”

[Luger \(2005\)](#)

De tal forma que si hilamos estas definiciones con la antes dada para el machine learning, podemos darnos cuenta que es un caso particular de la inteligencia artificial, ya que el machine learning busca brindar a las máquinas la capacidad de aprender a partir de datos, y aunque el propósito no sea emular el razonamiento humano, la importancia del machine learning reside en poder capturar patrones y predecir resultados futuros con cierta medida de la incertidumbre. Este mismo tiene varios subtipos o ramas, las cuales son:

- **Aprendizaje supervisado**
- **Aprendizaje no supervisado**
- **Aprendizaje semi-supervisado**
- **Aprendizaje por refuerzo**
- **Aprendizaje por lotes y en línea**

Y de la misma forma en que el machine learning hace parte de la inteligencia artificial como una rama dentro de esta disciplina, así como todos los tipos de aprendizaje automático que mencionamos anteriormente, el diagrama 2.3 ejemplifica perfectamente la jerarquía entre inteligencia artificial, machine learning e incluso el deep learning o aprendizaje profundo que es un tipo de aprendizaje automático, una de las definiciones más famosas es la siguiente:

”Deep learning is a class of machine learning algorithms that use multiple layers to progressively extract higher-level features from the raw input.”

LeCun et al. (2015)

De hecho uno de los diferenciadores principales entre el deep learning y los demás tipos de aprendizaje automático es la que se menciona en la definición anterior, los modelos de deep learning, los cuales suelen ser Redes neuronales, minimizan la intervención humana a la hora de selección de características, lo que permite una mayor automatización y eficiencia en problemas de complejidad mayor.

Podríamos continuar hablando acerca de todas las ramas en las que se especializa la inteligencia artificial sin embargo no es el propósito de este trabajo. Pero algo que si esta dentro del alcance de este trabajo es el aprendizaje supervisado, el cual es una de las ramas más importantes dentro del aprendizaje automático y la base principal para elaborar modelos predictivos como los que podríamos usar para predecir y explicar el churn.

En términos generales este enfoque es muy parecido al ejemplo del diagrama 2.2, entrenamos nuestro modelo (sistema) con datos históricos como ejemplos de entrada, cada uno de los cuales esta asociado a una salida esperada. El objetivo es que este modelo aprenda las distintas relaciones que pudieran existir entre las diferentes variables que se le presenten estas asociadas a un resultado, y este mismo sea capaz de predecir salidas de forma correcta a datos sin un resultado definido.

En términos matemáticos el sistema buscar aprender una función que explique la relación entre las variables de entrada, el cual común mente es llamado matriz de características o variables explicativas, y la variable objetivo. Este proceso puede expresarse de la siguiente manera:

$$f : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}^n \quad (2.1)$$

Donde $\mathbb{R}^{n \times m}$ representa la matriz de características con n observaciones o filas y m características o columnas, por otra parte $\mathbb{R}^n$ es la variable objetivo o termino dependiente, este mismo es el vector de los valores de salida esperados de orden n , además nos referiremos a f como ”modelo”.

En el caso del Churn cada fila de la matriz $n \times m$ es un cliente, por lo cual tendríamos n clientes con m características, las cuales pueden ser consumo, frecuencia de compra,




Figura 2.3: Relación entre IA, ML, Deep Learning y tipos de aprendizaje automático

etc. Similarmente las salidas nos indican si un cliente abandono o no, lo cual se puede representar como un vector $\mathbf{y} = [y_1 \ y_2 \ \dots \ y_n]$, con $v_i \in \{0, 1\}, \forall i \in 1, 2, \dots, n$.

El aprendizaje supervisado resuelve distintos tipos de problemas entre los cuales se encuentra los de tipo regresión y clasificación, mismos que podemos ver ilustrados en el diagrama 2.4, en esta tesis solo abordaremos en profundidad los problemas de clasificación ya que el churn puede reducirse a eso.

El diagrama 2.4 nos muestra que los problemas de regresión, clasificación o segmentación (que son un tipo de aprendizaje no supervisado) no son exclusivos del aprendizaje supervisado o no supervisado, sino que también pueden ser resueltos con ayuda de redes neuronales, todo depende de la cantidad de datos que tengamos a nuestra disposición o el nivel de intervención para selección de características.

2.2.1. Algoritmos de clasificación

El churn se puede reducir a un problema de clasificación, más en específico a una clasificación binaria. Los algoritmos de clasificación permiten predecir la pertenencia de una observación a una categoría o clase definida. En el contexto del churn, el objetivo




Figura 2.4: Tipos de aprendizaje automático con ejemplos de tareas y algoritmos

es predecir si un cliente se mantendrá activo o si abandonará la empresa en un periodo determinado.

A continuación, se presentan algunos de los algoritmos de clasificación más comunes y efectivos utilizados para este propósito:

Hasta acá termina mi avance

2.2.1.1. Regresión logística

2.2.1.2. KNN

2.2.1.3. Random Forest

2.2.1.4. SVM

2.3. Predicción del churn.

En esta sección abordaremos todos los conceptos concernientes con el churn,

2.3.1. Definición de *churn*

De hecho Gold (2020, p. 36) define el origen de la palabra *churn* en el término *churn rate*, este termino hace referencia a la proporción de clientes que abandonan la empresa en un periodo determinado.

Más en específico el *churn* es un estado u estatus que se le da a un cliente habitual de una empresa o servicio cuando este da por terminada la relación comercial, este concepto ha sido acuñado más recientemente por aquellas empresas que prestan servicios de suscripciones, como pueden ser plataformas de entretenimiento digital, proveedores de servicios de telecomunicaciones (internet, telefonía y/o televisión), etc. Sin embargo el *churn* no es únicamente aplicable a este tipo de compañías.

Ya que solo necesitamos que la empresa en cuestión oferte uno o más productos de los cuales tenga consumidores habituales para poder estudiar el *churn* en toda su cartera de clientes y más en específico poder abordar distintas estrategias para la retención de clientes.

En general el estudiar el comportamiento de los clientes puede ser un reto distinto dependiendo de la empresa e industria en la cual el científico de datos o analista de datos se encuentre, por lo cual es necesario tener pleno conocimiento sobre las reglas de negocio en cuestión. Ya que cada caso de estudio necesitará de enfoques distintos para poder entender de mejor manera el *churn* y cómo combatirlo.

De hecho ese debería ser el propósito principal de estudiar el *churn*, poder proporcionar una radiografía certera sobre el comportamiento de los clientes en una empresa, esto eventualmente permitirá a los líderes dentro de la organización poder tomar decisiones basadas en datos, y es tarea del científico de datos proveer la información lo más clara y precisa posible.

2.3.2. Cálculo del *churn*

Anteriormente expusimos la diversidad de enfoques del *churn*, que hay empresas dedicadas a ofertar servicios de suscripciones o que simplemente tienen una cartera

de clientes habituales, pese a todo esto no todas las empresas tienen un indicador de abandono, de hecho en la mayoría de los casos lo primero sea determinar de manera correcta cuando un cliente a abandonado.

Para ellos en nuestro conjunto de datos asignaremos como *churn* a una columna cuyos registro sea true o false, esta fungirá como una bandera de abandono donde el valor true indica que un cliente abandono y False el caso contrario, como construir esta columna sera parte importante de este trabajo.

En el caso de las empresas que ofrecen suscripciones puede no aplicar, ya que saber cuando un cliente ha abandonado la compañía es más sencillo, podemos simplemente asignar el valor de True en la columna *churn* a todos aquellos que no cuentan con una suscripción activa y como False a los casos contrarios, y como mencionamos anteriormente, hablaremos da como construir el indicador de *churn*, para usar esta forma de determinar el *churn* es necesario contar con una variable que nos indique el tiempo desde la ultima transacción del cliente, y aun que no contemos con este dato podríamos determinarlo fácilmente de la siguiente manera:

```
1 fecha_ref = pd.Timestamp(datetime.now().date())
2 df['Tiempo_ultima_compra'] = df.groupby('bp_id')['Date_Last'].
    transform(lambda x: np.abs((fecha_ref - x.max()).days))
3
```

Donde '*fecha_ref*' es la variable que almacena la fecha del sistema cuando se ejecuta el programa, otra alternativa sería asignar a '*fecha_ref*' un día en específico, ejemplo el fin de mes. Por otra parte necesitamos una columna auxiliar en nuestro dataframe para realizar el calculo final que es el tiempo desde la ultima compra, esta columna es '*Date_Last*', esta contiene la ultima fecha de compra del cada cliente y en base a esta calcularemos el tiempo transcurrido desde la ultima compra, tal y como se muestra en el código ??.

Una vez determinada la columna '*Tiempo_ultima_compra*' conviene analizar la distribución de los valores para dicha variable, esto nos permite ver el comportamiento general de cada individuo¹, en este caso, podemos visualizar el histograma de la variable en cuestión (figura 2.5) en la cual podemos apreciar que gran parte de los clientes no sobrepasan los 125 días de inactividad de compra, y de hecho podemos notar una linea vertical de color roja que indica el percentil 75² de la variable '*Tiempo_ultima_compra*' lo cual nos indica que los clientes con un tiempo de inactividad demasiado alto son realmente pocos.

¹En el capítulo 2 repasamos el análisis univariado y sus implicaciones teóricas, en esta sección nos enfocaremos unicamente en las aplicaciones.

²Para este ejemplo, decidí tomar el percentil 75, sin embargo la elección de percentil es a criterio del científico de datos y esta fuertemente ligado a las características de los datos con los que estemos trabajando, así que tómese este valor como lo que es, un ejemplo.




Figura 2.5: Histograma de Tiempo desde la ultima compra

Como sugerencia, conviene que incluyamos una columna en nuestro dataframe que contenga el percentil que deseamos tomar como condición para determinar el abandono, puedes seguir el ejemplo que se muestra en el código 2.1 como ejemplo de como realizar el calculo del k-esimo¹ percentil.

```
1 df['percentile_k'] = np.percentile(df['Tiempo_ultima_compra'], k)
```

Listing 2.1: Ejemplo de como determinar el percentil n

Una vez hecho el análisis del comportamiento de las ultima compra registrada de cada clientes y de haber calculado el percentil es hora de determinar la columna *churn* dentro de nuestro dataframe, por lo cual nos apoyaremos del código 2.2.

```
1 df['Churn'] = np.where(df['Tiempo_ultima_compra'] > df['percentile_k'], True, False)
```

Listing 2.2: Ejemplo de como determinar el churn.

Por ultimo, en la figura 2.6 podemos apreciar la proporción del *churn* en los clientes a analizar, y el resultado de la codificación anterior, en la gráfica de pie podemos notar que existe cierto desbalance en la proporción de clientes abandonadores y no abandonadores, recordemos que a posteriori esto puede ser un problema en la implementación de modelos de clasificación binaria, lo cual fue abordado en el capítulo 2.

¹Donde k es el valor del percentil a determinar.




Figura 2.6: Gráfica de tarta para el abandono de clientes.

En estas ultimas secciones he abordado a profundidad el concepto de *churn*, el como analizar la actividad de compra de los clientes nos ayuda a comprender a como determinar el *churn*, por lo cual en la siguiente sección realizaremos un tipo de análisis más enfocado al comportamiento histórico de los clientes y ver cual ha sido el *churn* y retention rate.

2.3.3. Métricas y causalidad del *churn*

Pese a que existen numerosas estrategias que podrían ayudar a disminuir la tasa de abandono y por lo tanto combatirlo, cabe resaltar que no nos enfocaremos en explicar dichas estrategias, más bien, nos enfocaremos en como aprovechar las razones subyacentes al *churn* para poder definir buenas métricas ¹ que ayuden a evaluar el comportamiento de los clientes, y así poder usar estas mismas métricas en una eventual predicción del *churn*, el cual es propósito final de este trabajo.

Una definición de métrica para clientes puede ser la provista por Gold (2020, p. 51) “*cualquier medición que realice sobre todos los clientes individualmente*”. Por lo cual es crucial encontrar las mejores metricas para monitorear a los clientes, de hecho Gold (2020) menciona las siguientes características importantes que debe tener una buena métrica; debe ser fácil de entender para la empresa, deben estar asociada con el

¹En este caso cabe aclarar que otros sinónimos con los nos referiremos a las metricas son características, dimensiones o variables predictoras.

churn y la retención, segmenta a los clientes de manera que facilita las intervenciones dirigidas a disminuir el *churn rate* y sobre todo es útil para múltiples áreas de la empresa (marketing, soporte, etc.)

En el capítulo anterior discutimos sobre la importancia de seleccionar correctamente las características para implementar *modelos de clasificación binaria*, mencionamos diversas técnicas de reducción de dimensiones basadas en criterios estadísticos, sin embargo, hay que considerar otras pautas a la hora de escoger dichas dimensiones si lo que deseamos es predecir el *churn*, estos juicios alternativos obedecen más a las reglas del negocio o empresa. Claro siempre hay que analizar la relación que pudieran tener con el *churn*.

2.3.4. Análisis de Cohortes y la tasa de abandono

Analizar el comportamiento del abandono de clientes a lo largo del tiempo nos puede ayudar a encontrar conductas que a simple vista suelen pasar desapercibidas. Por lo tanto cabe aclarar el significado de cohorte, (Gold, 2020) lo define como un grupo de individuos que son similares, y de hecho lo que nos interesa en este trabajo es estudiar esa similitud a lo largo del tiempo para poder encontrar patrones en el comportamiento del abandono de clientes.

Por lo cual los grupos que definiremos serán periodos de tiempo, agruparemos aquellos clientes que tuvieron actividad durante dichos periodos, en particular para este trabajo definiremos los cohortes como meses, pero bien podrían ser semanas, años, etc. El objetivo de identificar estos cohortes es tener mayor claridad de la actividad mensual de los clientes y poder hacernos las siguientes preguntas. ¿Cuántos clientes activos tiene una empresa por mes? ¿Cuántos clientes nuevos han adquirido? y ¿Cuántos clientes han perdido?

Podemos estudiar el comportamiento de estos cohortes usando diferentes métricas, ya sea por el número de suscripciones a un servicio, volumen de compra, valor de compra o número de clientes activos, este último es la que usaremos en este trabajo, ya que esto nos permitirá relacionarlo con un concepto previamente visto, el *churn rate*.¹

Hacer este análisis en python es tarea sencilla, primero es necesario tener la fecha de compra o fecha de facturación contenida en nuestro dataframe, cabe aclarar que este ejercicio podría hacerse antes de determinar la variable de abandono, esto para evitar tener la correcta dimensión del dataframe con el que deseamos trabajar, ya que el nivel de detalle que deseamos tener para realizar este análisis es por fecha de compra, consumo, producto y clientes o usuarios. Aclarado lo anterior, podemos comenzar a revisar los pasos a seguir para hacer este análisis:

Duda: ¿Será mejor mostrar esto como pseudocódigo?

¹Antes de continuar tenemos que aclarar que hay distintos tipos de enfoques para agrupar los clientes, estos enfoques son inherentes al negocio o empresa en el cual se quiera implementar, además está fuertemente ligado a la información que tengamos disponible, por lo cual hay que tener en cuenta estas limitantes antes de llevar a cabo el análisis de cohortes.

1. Ordenar las observaciones de nuestro dataframe por fecha y id de usuario.¹
2. Crear una variable que almacene el desplazamiento de cada cohorte en meses posteriores, esta variable nos ayuda a identificar los periodos de desplazamiento posterior a la adquisición de los clientes.
3. Determinar el mes de adquisición del cohorte de clientes.
4. Contar los clientes activos mensuales de cada cohorte y sus desplazamientos posteriores.
5. Del conteo final hay que tomar los clientes iniciales de cada cohorte y dividir todos los conteos por el número de clientes iniciales.

A continuación mostraremos la implementación de dicho análisis, el primero de los pasos esta ilustrado en el código 2.3

```
1 df.sort_values(by=['Fecha', 'bp_id'], inplace=True)
```

Listing 2.3: código del paso 1 del analisis de cohorte

Y es que como bien lo indican las instrucciones simplemente tenemos que ordenar nuestro dataframe haciendo uso de la API de pandas.

Ordenar los datos de esta manera nos asegura que los cohortes que creemos tengan coherencia cronológicamente, esto porque en el paso 2 y 3 para determinar el mes de adquisición del cohorte y los meses de desplazamiento nos basamos en los meses de actividad de los clientes, en el código 2.4 creamos la columna *CohortMonth* la cual corresponde al mes de adquisición del cohorte, mientras que *InvoiceMonth* es el mes de compra cada cliente.

```
1 def get_month(x): return dt.datetime(x.year, x.month, 1)
2
3 df['InvoiceMonth'] = df['Fecha'].apply(get_month)
4 grouping = df.groupby('bp_id')['InvoiceMonth']
5 df['CohortMonth'] = grouping.transform('min')
```

Listing 2.4: código del paso 2 del analisis de cohorte

De forma auxiliar y previo obtener el resultado final, necesitamos crear una función que extraiga los valores enteros de los campos *CohortMonth* y *InvoiceMonth*, en el código 2.5 mostramos la definición de dicho método.

```
1 def get_date_int(df, column):
2     year = df[column].dt.year
```

¹Es necesario que la variable que contenga la fecha sea del tipo de datetime para poder obtener una salida correcta en este paso y en los posteriores.

2. MARCO TEÓRICO Y CONCEPTUAL

```
3 month = df[column].dt.month
4 day = df[column].dt.day
5 return year, month, day
```

Listing 2.5: código para el método `get_date_int`

Análogamente para mejorar la forma en que vemos la información obtenida en el paso 3 nos apoyamos de la función `get_date_int`, el código 2.6 nos ayudará a crear una columna llamada *CohortIndex*, esta columna como su nombre es un conjunto de índices cuyo fin es representar los cohortes, osea nos permite tener una mejor visualización del desplazamiento de cada grupo de clientes.

```
1 invoice_year, invoice_month, _ = get_date_int(df, 'InvoiceMonth')
2 cohort_year, cohort_month, _ = get_date_int(df, 'CohortMonth')
3 years_diff = invoice_year - cohort_year
4 months_diff = invoice_month - cohort_month
5 df['CohortIndex'] = years_diff * 12 + months_diff + 1
```

Listing 2.6: código para la obtención de la columna *CohortIndex*

Por otra parte, para obtener el paso 4 debemos hacer uso de una pivot table agrupar los datos por *CohortMonth* y *CohortIndex*, así como agregar para obtener el resultado final, en el código 2.7 podemos observar como llevar acabo esta implementación. La utilidad de usar una tabla pivote para mostrar el resultado es porque gracias a esta forma podremos visualizar de mejor manera el desplazamiento desde el momento de adquisición para cada cohorte hasta la ultima actividad.

```
1 grouping = df.groupby(['CohortMonth', 'CohortIndex'])
2 cohort_data = grouping['pd_id'].apply(pd.Series.nunique)
3 cohort_data = cohort_data.reset_index()
4 cohort_counts = cohort_data.pivot(index='CohortMonth',
5 columns='CohortIndex',
6 values='pd_id')
```

Listing 2.7: código para la obtención de la columna *CohortIndex*

Finalmente para poder obtener la matriz de tasa de retención tenemos que llevar acabo el paso 5, la implementación la mostraremos en fragmento de código 2.7 se crea la variable *cohort_sizes* que toma la primera columna, esta representa el número de clientes iniciales de cada cohorte, una vez hecho esto crearemos la tabla pivote final llamada *retention*, la misma es resultado de dividir toda la pivot *cohort_counts* por *cohort_sizes*, tal y como se muestra en la ecuación 3.1, de hecho ya podemos explicar el porque la ecuación del *churn rate* considera el numero de clientes por periodos de tiempo, y es que esta es la mejor forma de analizar la tasa de retención.

```

1  \# Dependencias
2  import seaborn as sns
3  import matplotlib.pyplot as plt
4  \# Calulo de la matriz de retencion
5  cohort_sizes = cohort_counts.iloc[:,0]
6  retention = cohort_counts.divide(cohort_sizes, axis=0)
7  retention.round(3) * 100
8  \# Visualizacion de matriz de retencion.
9  plt.figure(figsize=(35, 30))
10 plt.title('Retention rates')
11 sns.heatmap(data = retention,
12 yticklabels=df['CohortMonth'].sort_values().apply(lambda x: x.strftime
    ("%Y %b, %d")).unique(),
13 annot=True,
14 linewidths=.2,
15 fmt='.0%',
16 cmap='coolwarm',
17 vmin=0,
18 vmax=1)
19 plt.show()

```

Listing 2.8: código para la obtención de la columna *CohortIndex*

La gráfica 2.7 nos muestra el resultado final de las anteriores codificaciones, en los registros correspondientes a la primera columna podemos observar que la tasa de retención es siempre del 100% esto se debe a que son los clientes que tienen su primer actividad de compra dentro de ese cohorte, de tal forma que los registros de las columnas posteriores representan la actividad de los clientes después de su adquisición, por ejemplo, el cohorte enero de 2022 en el segundo mes¹ (febrero de 2022) podemos observar una retención del 76% de los clientes iniciales y para el ultimo indice podemos notar que se mantuvieron 64% de los clientes que iniciaron en enero del 2022, esto quiere decir que en **Fecha final** se perdió el 36% de los clientes ingresados en enero

¹Ya que cada numero es una representación simplificada de cada cohorte, es importante tomar en cuenta que dicho numero se toma apartir del cohorte inicial, por ejemplo, para el cohorte enero de 2022 el numero 1 es igual al mismo mes, en cambio el numero 2 significa febrero de 2022, de forma similar el numero 3 es equivalente a marzo del 2022 y así sucesivamente hasta llegar al ultimo mes, por consecuencia ultimo mes solo tendrá datos hasta el indice 1, el penúltimo contiene información hasta el indice 2, etc.

2. MARCO TEÓRICO Y CONCEPTUAL

de 2022, esto dicho grupo de clientes tiene un comportamiento de compra habitual y guardan cierta fidelidad.

Similarmente, los clientes adquiridos en agosto de 2022 tienen un comportamiento similar hasta 6 meses después de la adquisición, sin embargo es a partir del mes 7 que este comportamiento baja al 40 %. El general la tasa de retención de clientes adquiridos en cada cohorte es bajo , ya que para el mes más reciente de cada cohorte podemos notar una baja tasa de retención, lo cual indica que la empresa ha perdido más clientes de los que ha ganado en los últimos meses.

2.4. Inteligencia artificial explicable (XAI)

2.4.1. SHAP

2.4.2. LIME

2.4.3. Importancia de características




Figura 2.7: Matriz de Cohortes.

Metodología de análisis y preparación de los datos

3.1. Descripción del conjunto de datos

Una parte crucial en toda implementación de Machine Learning es la calidad de los datos, y es algo que cuando se hacen implementaciones sobre información real cobra mucha relevancia, ya que en términos generales es deber del científico de datos a cargo, asegurarse que dicha información sea de calidad.

Ya sea asegurarse del cumplimiento de los supuestos que cada modelo de machine learning demanda ó bien, asegurarse que la calidad de la información sea la adecuada para poder obtener las mejores estimaciones y evitar problemas de Under-fitting o Over-fitting.

En la mayoría de las implementaciones de Machine Learning necesitamos recolectar la información desde alguna fuente de origen, ya sea una base de datos, data lake o cual sea la fuente de la que provengan nuestros datos, por lo cual sera de vital importancia tener total conocimiento acerca del sistema de origen de la información. En consecuencia parte del pipeline que se va a preparar comprende la extracción de la información y en algunos casos preparar un primer procesamiento que nos asegure trabajar con el nivel de especificación que deseamos.

Para el caso particular presentado en este trabajo, es necesario asegurarnos que el nivel máximo de detalle en nuestros datos sean clientes, osea que cada campo y registro debe hacer referencia a información de los clientes, como su historial de compras, año de registro, etc. Y por lo tanto un primer paso sería validar que estemos trabajando con registros únicos.

En consecuencia es importante conocer todos los detalles posibles de los datos con los que vamos a trabajar, tanto en lo concerniente al negocio o a las propiedades inherentes de los datos, esto sera mejor abordado en el siguiente apartado.

3.2. Preprocesamiento

3.2.1. Limpieza y tratamiento de valores faltantes y outliers

3.2.2. Transformaciones y codificación

3.2.3. Selección y reducción de características (PCA)

3.3. Construcción de la variable de abandono (churn)

En este capítulo abordaremos el concepto de abandono de clientes, al ser este uno de los fenómenos que deseamos analizar y predecir, es de suma importancia comprender el concepto de abandono, esto para tener completo entendimiento sobre el comportamiento de los clientes y el fuerte impacto que puede tener el conocer el abandono dentro de una organización. En adelante nos referiremos al abandono como *churn* y a la tasa de abandono como *churn rate*.

La forma que usaremos para calcular la tasa de abandono en este trabajo sera la dada por 3.1, como podemos apreciar esta expresión considera cierto enfoque temporal, más adelante abordaremos el porque.

$$\text{Churn Rate} = \frac{\text{Número de clientes en el ultimo periodo}}{\text{Total de clientes}} - 1 \quad (3.1)$$

De hecho si tomamos la razon entre el numero de clientes en el ultimo periodo o en el actual y el total de clientes tendremos la tasa de retención de clientes. Entendiendo que la tasa de retención es el complemento de la tasa de abandono.

3.4. Implementación de modelos de ML para predecir el abandono

Una vez entendido el concepto de retención y abandono de clientes y las tasas y el análisis de cohorte, comenzaremos por mostrar la implementación de algoritmos de Machine Learning que nos permitan realizar predicciones del abandono. Recordemos que definimos la columna churn (abandono) como una variable de tipo binaria, donde true indica que un cliente abandono y false el caso contrario, en este caso nuestra variable objetivo sera la columna churn.

En esta sección nos apoyaremos de las herramientas vistas en la sección 2 y más en específico llevaremos acabo la implementación de modelos de clasificación binaria para poder predecir las etiquetas de la variable churn, por lo cual no profundizaremos mucho en la teoría detrás, sino nos enfocaremos unicamente en los resultados obtenidos y la interpretación de los mismos.

Para este trabajo compararemos los resultados de distintos modelos de clasificación binaria, tomando en cuenta las metricas de evaluación como precisión, exactitud, etc, haciendo uso tanto de herramientas visuales y resúmenes estadísticos veremos las desventajas y ventajas de cada modelo, esto eventualmente nos conducirá a determinar el modelo que mejor realice la clasificación.

Antes de empezar con el análisis comparativo, es conveniente aclarar que los modelos que en adelante analizaremos ya fueron optimizados y entrenados en el capitulo anterior, por lo cual en esta sección tomaremos como punto de partida lo visto en el capitulo anterior.

3.4.1. Evaluación del modelo.

Previo a la profundización en cada modelo y sus resultados veremos como evaluar el rendimiento de cada modelo, en esta sección utilizaremos como ejemplo el modelo multi-layer perceptron classifier, por lo cual lo visto de aquí en adelante es fácilmente reproducible a cualquier otro modelo. Partiremos de las predicciones con el conjunto de datos de validación, así nos apoyaremos de la matriz de confusión y curva roc para evaluar nuestros modelos de forma visual y numérica.




Figura 3.1: Matriz de confusión para el modelo de multi-layer perceptron classifier.

3. METODOLOGÍA DE ANÁLISIS Y PREPARACIÓN DE LOS DATOS

En la gráfica 3.1 podemos apreciar el numero de aciertos (verdaderos positivos y negativos) y el numero de errores (falsos positivos y negativos) cometidos por el modelo. La representación gráfica anteriormente mencionada es la matriz de confusión asociada al modelo de multi-layer perceptron classifier, de hecho esta gráfica nos permite encontrar la mayoría de las metricas para evaluar nuestro modelo. Por ejemplo, la ecuación 3.2¹ nos proporciona la *accuracy* o exactitud, esta métrica nos indica el porcentaje de acierto que tuvo el modelo. Python nos facilita el calculo de esta métrica, el código 3.1 muestra un ejemplo de como calcular la accuracy haciendo uso del sklearn.

Aquí pienso colocar el análisis de la matriz de este modelo, decidí no añadirlo por que puede cambiar.

$$\text{accuracy} = \frac{TP + TN}{(TP + TN + FP + FN)} \quad (3.2)$$

Sin embargo Peterson (2023) menciona que la accuracy usualmente no es una buena métrica para evaluar modelos cuando tenemos clases desbalanceadas en nuestra variable objetivo, lo cual es nuestro caso, ya que como mencionamos anteriormente la variable *churn* tiene más registros marcados como *false*, aun que en el capitulo anterior explicamos la forma en que lidiamos con el desbalance de las clases, explicaremos por que no siempre es conveniente optar por la exactitud, esto porque puede encubrir un incorrecto funcionamiento del modelo, por ejemplo, la matriz 3.1 podemos notar que el total de las observaciones que inicialmente fueron clasificadas como false son mayores a las clasificados como true, el problema es que aunque el porcentaje de aciertos en la clase con dominante es medianamente aceptable, siento mayor a 90 %, la clase minoritaria muestra un menor rendimiento, **insertar porcentaje** esta cifra indica el mal rendimiento para los registros clasificados como true.

Y es que aun que la clase true sea minoritaria, nos interesa tener la mayor cantidad de predicciones correctas para que en un futuro poder predecir correctamente los clientes que están abandonaran la compañía. Por lo tanto recomendamos optar por otras metricas para tener una visión mas completa del rendimiento de nuestro modelo.

```
1 from sklearn.metrics import accuracy_score, confusion_matrix,
   classification_report, precision_score, recall_score, f1_score
2 print("Accuracy: {}".format(accuracy_score(y_true=valid['y'], y_pred=
   valid['y^_MLP'])))
3 print("Precision: {}".format(precision_score(y_true=valid['y'], y_pred=
   valid['y^_MLP'])))
4 print("Recall: {}".format(recall_score(y_true=valid['y'], y_pred=valid[
   'y^_MLP'])))
```

¹Las variables TP, TN, FP y FN son el numero de casos true positives, true negatives, false positives y false negatives respectivamente.

```
5 print("F1: {}".format(f1_score(y_true=valid['y'], y_pred=valid['y^_MLP'])))
```

Listing 3.1: código para calculo de metricas

Algunas de las metricas a las que podemos recurrir son precision (precisión), recall (sensibilidad o recuperación) y F_β . Aun que existe muchas otras metricas, nosotros nos enfocaremos solo en estas. La precisión (ecuación 3.3) es el número de aciertos, predicciones correctas, entre el total de casos positivos captados por el modelo, osea del total de casos clasificados como true, cuales son realmente true, mientras que la sensibilidad (ecuación 3.4) es el numero de predicciones correctas, entre el total de casos positivos, es decir es la proporción de casos clasificados como true.

$$\text{precision} = \frac{TP}{(TP + FP)} \quad (3.3)$$

$$\text{recall} = \frac{TP}{(TP + FN)} \quad (3.4)$$

Hay distintas ventajas de usar una u otra métrica para evaluar nuestro modelo, si nosotros decidimos inclinarnos por la recall, estaríamos dando mayor importancia a reducir la cantidad de errores cometidos por el modelo, esto nos indica que esta métrica no nos aporta información acerca de los falsos positivos, y lo mismo pasa con la precision, ya que al querer reducir el numero de falsos positivos estaríamos ignorando el rendimiento del modelo frente los falsos negativos, por lo cual escoger una u otra es decisión del científico de datos a cargo, en el código 3.1 nos muestra como calcular estas dos metricas con ayuda de Python.

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{\beta^2 \cdot (\text{precision} + \text{recall})} \quad (3.5)$$

La métrica que nos permite encontrar un equilibrio entre el numero de FP y FN es el F-score, esta métrica combina tanto la precision y recall en un solo valor, la ecuación 3.5 nos permite calcular dicho valor. El parámetro de β nos da la posibilidad de otorgarle un nivel de importancia a la precision o recall. De hecho si el valor de β es igual a cero el F-score le da mayor importancia a la precision, mientras que cuando β es igual a 0.5 el $F - score$ le da mayor peso a la recall, por ultimo si β es igual a 1, obtenemos el F_1 -score (ecuación 3.6) le damos igual importancia a ambas metricas, de esta forma podemos evaluar tanto el número de falsos positivos y negativos.

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{(\text{precision} + \text{recall})} \quad (3.6)$$

De la comparación entre precision y recall, surge otra forma de evaluar modelos de clasificación binaria, esta métrica es la curva roc (Receiver Operating Characteristic), **Géron** (2017, p. 91) nos dice que *la curva ROC representa gráficamente la tasa de*




Figura 3.2: Curva ROC.

verdaderos positivos frente a la tasa de falsos positivos. La FPR es la proporción de casos negativos que se clasifican incorrectamente como positivos.

En la gráfica 3.2 podemos notar que el eje de ordenadas está etiquetado como True Positive Rate (TPR), mientras que el eje de abscisas está etiquetado como False Positive Rate (FPR), donde las TPR puede ser también interpretado como la recall mientras que FPR suele interpretarse como el complemento de la especificidad ($1 - \text{especificidad}$), (Géron, 2017) menciona que un buen clasificador se mantiene lo más posible alejado de la línea vertical punteada, dicha línea diagonal sirve más como una referencia y es también llamada línea de no-discriminación.

Además de la curva roc, el área bajo la curva roc (comúnmente llamada AUC) es otra muy buena opción para medir el rendimiento de modelos de clasificación binaria, ya que un valor cercano a 1 de la AUC nos indicará que contamos con un buen clasificador, este buen rendimiento se considera respecto a la especificidad y recall, es decir, estas dos métricas nos indican que nuestro modelo en cuestión dará una mejor calificación a la probabilidad de un registro positivo seleccionado al azar que a un registro negativo seleccionado de forma aleatoria.

De hecho este último punto deja en evidencia que existe cierto inconveniente al evaluar nuestros modelos con la auc solamente, ya que la curva roc puede encubrir desbalances entre clases de la variable objetivo, Chugh (2023) plantea que la curva roc tiende a pasar por alto el desequilibrio entre clases, ya que la tasa de FP es una métrica que solo contempla a la clase negativa, lo que significa que se espera que el cambio en FP sea proporcional al cambio en FP+TN (todos los casos negativos), esto puede derivar en tener poca sensibilidad a cambios en la distribución de las clases de la variable objetivo.

Partiendo de este último punto y recordando que en nuestro caso la información que

estamos analizando tiene cierto desequilibrio entre clases de la variable a predecir, sin embargo no todo esta perdido, ya que existe otra métrica que nos proporciona mayor información que la auc y que no pasa por alto el desequilibrio en entre clases, esta métrica es la curva precision-recall, en palabras de [Chugh \(2023\)](#) *una curva ROC es similar a la curva PR (Precision Recall), pero traza la tasa de verdaderos positivos (TPR) frente a la tasa de falsos positivos (FPR) para diferentes umbrales... La PR es comparativamente más informativa. Esto se debe a que la curva P-R proporciona información más significativa sobre la clase de interés en comparación con la curva ROC.*




Figura 3.3: Curva PR.

Por lo tanto la curva PR nos ayudara a evaluar de mejor manera nuestros datos dando mayor importancia a los registros positivos pero sin dejar completamente de lado los negativos, encontrando así un equilibrio no arbitrario entre uno y otro. Esto porque uno de los grandes inconvenientes de elegir la auc sobre la PR es que en nuestro caso al tener mayor proporción de registros clasificados negativamente (osea como no abandono) hace que la tasa de FP sea demasiado pequeña, en comparación de la PR que al considerar la a la precision y por ende el rendimiento de nuestro modelo en los registros positivos.

3.4.2. Comparación del rendimiento entre modelos.

Analizaremos el rendimiento de nuestros modelos en el conjunto de entrenamiento y de validación haciendo uso de las metricas antes mencionadas. Por ejemplo, en la matriz de confusión del modelo de regresión logística para el conjunto de entrenamiento ([3.4 izquierda](#)) podemos notar signos de un mal desempeño a la hora de predecir

3. METODOLOGÍA DE ANÁLISIS Y PREPARACIÓN DE LOS DATOS

correctamente los registros positivos (abandonos) con respecto de los casos negativos (no abandonos), esto se hace más evidente en el caso de los falsos positivos, cuya presencia es mayor que los verdaderos positivos, lo cual se traduce inmediatamente en una precisión baja. Sin embargo en el conjunto de validación (derecha 3.4) podemos notar que este comportamiento persiste.




Figura 3.4: Matriz de confusión para el modelo de regresión logística del conjunto de entrenamiento y validación

De hecho nos podemos auxiliar de la gráfica de precisión vs recall (3.5) trazada para el modelo de regresión logística, en este caso claramente podemos notar que nuestro modelo no está teniendo un buen desempeño, esto se puede hacer más evidente si analizamos la accuracy, cuyo valor es demasiado bajo. En la gráfica 3.6 podemos ver el desempeño de cada una de las métricas antes mencionadas en nuestro modelo, vemos que tanto la accuracy y el F1 score tienen un mal desempeño, esta gráfica nos confirma el mal desempeño de este modelo tanto en el conjunto de entrenamiento y validación.




Figura 3.5: Curva PR de Regresión Logística

Por último inspeccionando la curva roc del modelo de regresión logística en la gráfica 3.13, podemos notar los vicios antes mencionados en nuestro modelo, dado que el “ideal” de un modelo es tener una area (auc) lo más cercana a uno, en la curva roc del conjunto de entrenamiento y validación del modelo de regresión logística podemos

notar que la $AUC_{train} = 0.86$ y $AUC_{valid} = 0.85$, esto aunado a que la curva roc es bastante cercana a la linea de no-discriminación, por lo cual podemos considerar a este modelo como un mal clasificador, dado que no cumple con el rendimiento esperado, por las razones antes mencionadas, lo cual eventualmente causaría conflictos, pues hay mayor posibilidad de clasificar de forma equivocada a un cliente como abandonador.




Figura 3.6: Metricas de evaluación del modelo de regresión logística para el conjunto de entrenamiento y validación

Por otra parte, el modelo KNN nos ofrece características más interesante, de inicio la matriz de confusión (3.7) tanto del conjunto de entrenamiento y validación a diferencia del modelo anterior podemos ver un menor numero de casos falsos positivos y por ende un mejor rendimiento a la hora de clasificar los casos verdaderamente negativos y positivos, si analizamos damos una rápida inspección a las metricas de evaluación del modelo podemos notar un mejor rendimiento en la presicion y por ende tenemos un mejor F1 score.




Figura 3.7: Matriz de confusión para el modelo KNN del conjunto de entrenamiento y validación

Esto ultimo lo podemos confirmar con la gráfica 3.8 en donde podemos ver una

3. METODOLOGÍA DE ANÁLISIS Y PREPARACIÓN DE LOS DATOS

mejora significativa en el rendimiento del modelo, teniendo una mejor accuracy e F1 score, sin embargo el modelo presenta un inconveniente que podemos apreciar. El rendimiento del modelo decrece en el conjunto de validación, esto con respecto del conjunto de entrenamiento, esto nos indica que este modelo en específico no generaliza del todo bien las predicciones, de hecho esto se hace evidente en las variaciones tan marcadas en las métricas que muestra el modelo, por ejemplo podemos ver que tan solo la accuracy del conjunto de pruebas y validación varía por 0.05, y que el F1 score varía 0.11, lo cual es una gran diferencia en el rendimiento de nuestro modelo, esto nos da indicios de que este modelo podría volverse obsoleto en el corto o mediano plazo, lo cual podría repercutir en futuros errores de clasificación.




Figura 3.8: Métricas de evaluación del modelo de KNN para el conjunto de entrenamiento y validación

De igual forma la curva roc del modelo KNN que podemos apreciar en las gráficas 3.13 vemos este decaimiento en el rendimiento en el conjunto de validación, notemos como la $AUC_{train} = 0.96$ baja $AUC_{valid} = 0.90$ lo cual confirma que este modelo no es confiable y por tanto lo descartaremos como modelo final para clasificar clientes.

Ahora vamos a analizar los resultados del modelo support vector machine (svm), de forma análoga inspeccionaremos brevemente las matrices de confusión del modelo, podemos notar en primera instancia (gráfica 3.9) que el comportamiento del clasificador en el conjunto de entrenamiento y validación es similar al comportamiento mostrado por los dos modelos anteriores en dichos conjuntos de datos.




Figura 3.9: Matriz de confusión para el modelo de soport vector machine del conjunto de entrenamiento y validación




Figura 3.10: Metricas de evaluación del modelo de SVM para el conjunto de entrenamiento y validación

De igual manera, al inspeccionar las metricas del modelo podemos darnos cuenta que de hecho el comportamiento de los valores de dichas metricas es muy similar al modelo KNN, en ambos modelos podemos notar diferencias considerables entre el rendimiento mostrado en el conjunto de entrenamiento y validación, teniendo una variación de 0.07 en accuracy y 0.15 en la F1 score.

En cuanto a la curva roc podemos notar de igual manera un comportamiento similar, en la gráfica 3.13 podemos notar que en ambos modelos el comportamiento en el conjunto de entrenamiento es similar, aun que el clasificador SVM esta un poco por debajo del modelo KNN, de hecho es gracias a la AUC del modelo que podemos confirmar este hecho, ya que la AUC_{train} del modelo KNN es igual 0.96 mientras que AUC_{train} de SVM es igual a 0.93, ambos valores son muy buenos, sin embargo al comparar el rendimiento de dichos clasificadores en el conjunto de validación es donde podemos ver las diferencias entre ambos modelos. En este caso SVM no baja demasiado su rendimiento con respecto al conjunto de validación, podemos ver que la AUC_{valid} es igual

3. METODOLOGÍA DE ANÁLISIS Y PREPARACIÓN DE LOS DATOS

a 0.90, por lo cual la variación en el rendimiento entre conjunto de entrenamiento y validación es de 0.03.

Entonces podemos ver que a diferencia del modelo KNN, el clasificador SVM no presenta síntomas de sobre ajuste, a diferencia del modelo anterior, por lo cual SVM se perfila a ser un muy serio candidato a ser nuestro modelo final.

Finalmente analizaremos los resultados del modelo Random Forest, de forma parecida a los anteriores modelos podemos percatarnos que las matrices de confusión de los conjuntos de entrenamiento y validación (fig. 3.11) parecieran tener un rendimiento muy similar a los modelos anteriores, sin embargo mirando un poco más detenidamente nos daremos cuenta que de hecho su rendimiento mayor al de otros modelos como SVM y KNN, ya que el número de FN y FP es más bajo en comparación de los modelos ya mencionados.




Figura 3.11: Matriz de confusión para el modelo random forest del conjunto de entrenamiento y validación

Este ultimo punto lo podemos reforzar revisando la gráfica 3.12, en la misma ver la alta efectividad de este modelo en el conjunto de entrenamiento, teniendo una accuracy de 0.94 y un F_1 de 0.9 siendo valores muy aceptables, sin embargo esta misma gráfica nos permite apreciar un gran inconveniente con este modelo, ese problema es el sobre ajuste, ya que en tanto la accuracy y el F_1 score tienen un bajo de rendimiento importante en el conjunto de validación, siendo de 0.7 y 0.16 para la accuracy y el F_1 respectivamente, lo cual claramente implica que este modelo no generalizara adecuadamente nuestra predicciones y no lo vuelve un mal candidato como modelo final a elegir.

3.4 Implementación de modelos de ML para predecir el abandono




Figura 3.12: Metricas de evaluación del modelo de random forest para el conjunto de entrenamiento y validación

Recapitulando, hemos comparado distintos modelos aplicando las métricas anteriores, enfocándonos sobre todo en tener un buen F_1 -score y Precision, por ejemplo el modelo de **regresión logística** muestra un desempeño bajo, ya que no logra discriminar correctamente entre los clientes abandonadores y no abandonadores, por otro lado el modelo **KNN** tiene un mejor rendimiento que el modelo anterior, sufre de sobreajuste, lo cual nos lleva a concluir que no va a generalizar bien, por lo cual tenemos un potencial riesgo de obsolescencia en predicciones futuras, sin embargo en términos generales el modelo que cumple con el mejor desempeño general es el **SVM** esto debido a que tiene el mejor balance entre el conjunto de entrenamiento y validaciones, tiene mejor capacidad de generalización que el modelo anterior y por último tenemos el modelo con el rendimiento más alto en los datos de entrenamiento, pero disminuye bastante su rendimiento en el conjunto de validación, lo cual es un claro ejemplo de sobreajuste y por lo cual es un modelo que no generaliza bien.




Figura 3.13: Curvas Roc de los modelos de clasificación para el conjunto de entrenamiento y validación respectivamente.

3.4.3. IA Explicable.

Dicho lo anterior, y con el propósito de interpretar de mejor manera el comportamiento de nuestro modelo final de clasificación, vamos a utilizar técnicas de **Explainable IA (XAI)**, todo esto apoyándonos de la librería SHAP, como dato curioso esta librería debe su nombre a **SHapley Additive exPlanations** que a su vez debe su nombre a Lloyd Stowell Shapley quien fuera un destacado matemático y economista estadounidense, y entre sus grandes aportes a la teoría de juegos y a la ciencia de datos se encuentran los valores de Shapley, los cuales son la base de los valores Shap. La idea es simple en ejecución, según la documentación de la librería "SHAP es un enfoque de teoría de juegos para explicar la salida de cualquier modelo de aprendizaje automático".

El propósito de esta metodología es poder dar una explicación clara de como los modelos muy complejos toman decisiones, en nuestro caso saber como el modelo de Support Vector Machine decide si un cliente es abandonador o no. Si bien nos podemos dar una idea acerca del funcionamiento de este modelo, usando SHAP podemos saber como cada característica impacta en las predicciones de nuestro modelo, de tal manera que "las características con valores SHAP positivos tienen un impacto positivo en la predicción, mientras que las que tienen valores negativos tienen un impacto negativo. La magnitud es una medida de cuán fuerte es el efecto." **cita**




Figura 3.14: Gráfica de resumen global




Figura 3.15: Gráfica de explicación local

3.4 Implementación de modelos de ML para predecir el abandono




Figura 3.16: Gráfica de decisiones

Implementación y evaluación de modelos predictivos

4.1. Implementación de modelos de clasificación

4.1.1. Descripción de cada modelo y sus supuestos

4.2. Evaluación de desempeño de los modelos

4.2.1. Métricas: Accuracy, Precision, Recall, F1, AUC, PR

4.2.2. Comparación de resultados

4.3. Aplicación de XAI a modelos seleccionados

4.3.1. Interpretación de resultados y visualizaciones

Discusión y análisis de resultados

- 5.1. Discusión de hallazgos relevantes
- 5.2. Limitaciones del modelo
- 5.3. Recomendaciones para su implementación en entornos empresariales reales

Conclusiones y líneas futuras

6.1. Conclusiones generales

6.2. Aportaciones teóricas, metodológicas y prácticas

6.3. Sugerencias para investigaciones futuras

Código/Manuales/Publicaciones

A.1. Apéndice

Apéndice

Bibliografía

- Chugh, V. (2023). Precision-recall curve in python tutorial. <https://www.datacamp.com/tutorial/precision-recall-curve-tutorial>. 28, 29
- Gold, C. (2020). *Fighting Churn with Data: The science and strategy of customer retention*. Manning. 12, 15, 16
- Géron, A. (2017). *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly. 5, 27, 28
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444. 9
- Luger, G. F. (2005). *Artificial Intelligence: Structures and Strategies for Complex Problem Solving*. Addison-Wesley, Boston, 5 edition. 8
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill Education. 5
- Peterson, M. (2023). *Marketing Analytics: Predicting Customer Churn in Python*. DataCamp. 26
- Russell, S. and Norvig, P. (2020). *Artificial Intelligence: A Modern Approach*. Pearson, Boston, 4 edition. 8